

ASTRATTO

Proponiamo la perdita per regione (RW) per la segmentazione delle immagini biomediche. La perdita a livello di regione è versatile, può simultaneamente tenere conto dello squilibrio di classe e dell'importanza dei pixel e può essere facilmente implementata come moltiplicazione a livello di pixel tra l'output softmax e una mappa RW. Mostriamo che, nell'ambito del quadro di perdita RW proposto, alcune funzioni di perdita, come Active Contour e Boundary loss, possono essere riformulate in modo simile con mappe RW appropriate, rivelando così le loro somiglianze sottostanti e una nuova prospettiva per comprendere queste funzioni di perdita. Indaghiamo l'instabilità di ottimizzazione osservata causata da alcune mappe RW, come le mappe Boundary loss distance, e introduciamo un principio matematicamente fondato per evitare tale instabilità. Questo principio fornisce un'eccellente adattabilità a qualsiasi set di dati e garantisce praticamente la convergenza senza ulteriori termini di regolarizzazione o trucchi di ottimizzazione. Seguendo questo principio, proponiamo una versione semplice delle mappe della distanza di confine chiamate mappe rettificate Region-wise (RRW) che, come dimostriamo nei nostri esperimenti, raggiungono prestazioni allo stato dell'arte con coefficienti di Dice simili o migliori e Hausdorff distanze rispetto a Dice, Focal, Cross entropy ponderata e Boundary loss in tre distinti compiti di segmentazione. Quantifichiamo l'instabilità di ottimizzazione fornita dalle mappe Boundary loss distance e dimostriamo empiricamente che le nostre mappe RRW sono stabili da ottimizzare.

INTRODUZIONE

La segmentazione delle immagini è una tipica fase di pre-elaborazione richiesta per l'analisi quantitativa delle immagini nelle applicazioni biomediche. ~~Una segmentazione accurata è fondamentale per misurare, ad esempio, la dimensione del tumore al cervello, che può determinare la dose di radiazioni somministrata ai pazienti durante la radioterapia [1].~~ La segmentazione manuale delle immagini richiede molto tempo ed è soggettiva, come dimostra il grande disaccordo tra le segmentazioni manuali di diversi annotatori (vedi ad esempio [2]). Pertanto, vi è un grande interesse nello sviluppo di strumenti affidabili per segmentare automaticamente le immagini mediche [3].

~~Le reti neurali convoluzionali (ConvNet) hanno mostrato prestazioni eccellenti in più attività di segmentazione, portando alla loro considerazione in applicazioni cliniche, come la segmentazione delle caratteristiche patologiche nella tomografia a coerenza ottica della retina [4], la segmentazione del glioblastoma [5] e la segmentazione della testa e del collo per la radioterapia [6].~~ Nella segmentazione delle immagini mediche, tenere conto dello squilibrio di classe e dell'importanza dei pixel è fondamentale per produrre segmentazioni accurate. Per importanza dei pixel, ci riferiamo al fenomeno in cui la gravità degli errori di classificazione dipende dalla posizione degli errori di classificazione. Ad

~~esempio, nella segmentazione del tumore, le classificazioni errate lontano dai confini del tumore possono essere più gravi che vicino ai confini.~~ Per considerare lo squilibrio di classe o l'importanza dei pixel, minimizzare simultaneamente più termini o funzioni di perdita è una strategia comune. Taghanaki et al. [7] ha combinato la perdita di entropia incrociata con la perdita di dadi per affrontare lo squilibrio di classe. Gerl et al. [8] ha combinato l'entropia incrociata con un termine di penalizzazione specifico del dominio. ~~Peng et al. [9] hanno combinato le funzioni Dice loss e Focal loss in un'architettura basata su DenseNet, e Kamran et al. [10] hanno combinato la perdita di cerniera e l'errore quadratico medio per aumentare l'accuratezza della ricostruzione in una rete avversaria generativa.~~ Tuttavia, la minimizzazione di più funzioni o termini di perdita richiede iperparametri aggiuntivi per bilanciare il contributo individuale di ciascuna funzione di perdita, poiché le funzioni di perdita producono valori in intervalli diversi, che, a loro volta, influenzano i gradienti durante la retropropagazione. . Di conseguenza, diventa necessaria una costosa messa a punto degli iperparametri. Inoltre, l'intreccio di perdite multiple rende poco chiaro se una specifica funzione di perdita da sola o i termini extra fossero responsabili per affrontare, ad esempio, lo squilibrio di classe. In questo articolo, proponiamo la perdita regionale (RW), un quadro generale in grado di considerare congiuntamente lo squilibrio di classe e l'importanza dei pixel senza ulteriori iperparametri o funzioni di perdita. Mostriamo che diverse funzioni di perdita ampiamente utilizzate, comprese le perdite di contorno attivo (AC) [11], distanza di Hausdorff (HD) [12] e Boundary [13], possono essere riformulate come perdite RW, rivelando le loro somiglianze sottostanti. Inoltre, le perdite di Boundary e HD sono instabili da ottimizzare e, come spiegato in [12, 13], è necessario combinarle con la perdita di Dice per aggirare tale instabilità di ottimizzazione. Tuttavia, non è chiaro se specificamente la perdita di dadi debba essere abbinata a perdite di confini o HD per ottenere un'ottimizzazione stabile e, cosa più importante, la causa esatta di questa instabilità di ottimizzazione è rimasta sconosciuta. Kervadec et al. [13] ha ipotizzato che l'ottimizzazione delle mappe della distanza dal bordo fallisca occasionalmente perché i primi piani vuoti (tutti zeri nella classe in primo piano) producono piccoli gradienti. Questa ipotesi descrive un tipico scenario di squilibrio di classe in cui la maggior parte dei pixel supera i pixel in primo piano e, di conseguenza, i pochi pixel in primo piano contribuiscono poco ai gradienti. In questo documento, spieghiamo, utilizzando il framework di perdita RW, perché queste funzioni di perdita sono instabili da ottimizzare e introduciamo un principio basato sulla matematica che porta alla stabilità dell'ottimizzazione.

I nostri contributi sono i seguenti:

- Presentiamo la perdita RW, una funzione di perdita che è unica nella sua capacità di tenere conto simultaneamente dello squilibrio di classe e dell'importanza dei pixel. Inoltre, mostriamo che alcune importanti funzioni di perdita (perdite AC [11], HD [12] e Boundary [13]) possono essere riformulate.

- Analizziamo la perdita e forniamo un'intuizione teorica ed empirica della causa dell'instabilità di ottimizzazione osservata, ma non compresa, e introduciamo un principio per correggere tale instabilità. Appliciamo questo principio per derivare mappe rettificate Region-wise (RRW) (Fig. 1, (d)) che non richiedono ulteriori funzioni di perdita, termini di regolarizzazione o trucchi di ottimizzazione per garantire la stabilità dell'ottimizzazione.
- Mostriamo che la perdita di RW con le nostre mappe RRW proposte ha raggiunto prestazioni allo stato dell'arte, producendo coefficienti di Dice e distanze di Hausdorff simili o migliori rispetto a Dice, Focal, entropia incrociata ponderata e perdite di confine su tre grandi set di dati biomedici [14, 15, 16].
- Abbiamo confrontato le strategie precedenti per aggirare l'instabilità dell'ottimizzazione con la perdita di Boundary e abbiamo dimostrato che, indipendentemente dalla strategia, le nostre mappe RRW hanno portato a meno fluttuazioni durante l'ottimizzazione e fornito una convergenza più rapida.